

(4A)

=	≠	CINE	DOC
0	5	0	9
4	6	5	10
2	8	11	33
0	9	19	38
4	2	28	55
2	7	30	69
0	10	37	76

LAS POSIC EN LOS DOCS ESTAN INTERMEDIAS ENTRE POS 1, Y TODO CODIFICADO EN 8

LEXICO CALCULANDO CON FRECU
→ POSICIONES CODIFICADAS PARCIAL
USANDO M=3 (CADA 3 POSICIONES
ENCABE EL TERMINO COMPLETO)

MADRE IGUEBA GISTRADO MAEFICO TAVANTIAL MANIFESTO
0 5 11 19 30 37

101001001110101001001010101110101110101010101001001001001001001010100
0 10 33 38 55 69 76
01001010100100100101010101110101110101010101010010010100
0 10 33 38 55
0100011010101010101010100
69 76

LOS ESTOS SON LOS PUNTEROS A DOCS CODIFICADOS COMO GASTA, PERO TAMBIEN HAY QUE VER SI SON POSICIONES DE CADA TERMINO Y FRECUENCIA (DOC 1 POS 1 P1... Pn DOC2...)

→ CON LOS DATOS DE LA TABLA POSICIONES Y DEL LEXICO CALCULANDO, PUEDO ORDENAR LOS TERMINOS

MADRE → MADREIGUEBA → MAGISTRADO → MAEFICO → MAEFITA → MANANTIAL → MANIFESTO

LO P/ OBSERVAR ESTOS TERMINOS, SE REALIZA UNA BUSQUEDA BINARIA SOBRE EL LEXICO Y SE VA ACCESANDO A CADA POSICION DEL LEXICO Y USANDO TANTOS PUNTEROS IGUALES O DISTINTOS DEL TERMINO MAEFICO SEGUN ME DICA CADA POSICION DEL LEXICO

~~MADREIGUEBA~~

AUNTA TENDR QUE OBSERVAR LOS DOCUMENTOS, FRECUENCIA Y POSICIONES DE CADA TERMINO SEGUN LOS PUNTEROS CALCULANDO → COMO ESTAN CODIFICADOS EN GASTA, SE QUE UNA FORMA DE DECODIFICAR GASTA ES → USAR LA CANTIDAD DE CEROS LA QUE HAY EN CADA COLUMNA DE NÚMEROS

$$X(x) = \text{LEN}(\text{BINARY}(x)) - 1 \text{ CEROS} + \text{BINARY}(x)$$

→ TODAS LAS DISTANCIAS (ENTRE DOCS VA CODIFICADAS EN GASTA)

ENTRE LAS POSICIONES 0 y 10 → 1010010011 → DOC 1, FREC 2, POSICION 2 y 3
1 2 2 3

ENTRE LAS POSICIONES 10 y 33 → 0110101001001010101111 → DOC 3, FREC 2, POS 1 y 4
3 2 1 4 1 2 1 3 1 1
→ DOC 4, FREC 2, POS 1 y 3
→ DOC 5, FREC 1, POS 1

ENTRE POS 33 y 38 → 01011 → DOC 2, FREC 1, POS 1
2 1 1

Euro Pos 38 y 55 - $\begin{array}{ccccccc} 1 & 1 & 1 & 0 & 1 & 0 & 1 & 0 & 1 & 1 & 0 & 1 & 0 & 1 & 0 & 1 & 0 \end{array}$ → DOC 1, FREQ 1, POS 1
 → DOC 3, FREQ 1, POS 3
 → DOC 5, FREQ 1, POS 2

→ Euro SS y 69 - $\begin{array}{ccccccc} 0 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{array}$ → DOC 2, FREQ 2, POS 2 y 4

→ Euro 69 y 76 - $\begin{array}{ccccccc} 0 & 1 & 1 & 1 & 0 & 1 & 0 \end{array}$ → DOC 3, FREQ 1, POS 2

→ Posiciones Fin Aca de 76 - $\begin{array}{ccccccc} 0 & 1 & 0 & 1 & 0 & 1 & 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 \end{array}$ → DOC 2, FREQ 1, POS 3
 → DOC 4, FREQ 1, POS 4

NOTA LOS DOCUMENTOS → Son 5 documentos

MANIFE → DOC 1, FREQ 2, POS 2 y 3

MANAGUERA → DOC 3, FREQ 2, POS 1 y 4; DOC 4, FREQ 2, POS 1 y 3; DOC 5, FREQ 1, POS 1

MANAGUERO → DOC 2, FREQ 1, POS 1

MANEFO → DOC 1, FREQ 1, POS 1; DOC 3, FREQ 1, POS 3; DOC 5, FREQ 1, POS 2

MANEBO → DOC 2, FREQ 2, POS 2 y 4

MANEHAL → DOC 3, FREQ 1, POS 2

MANEBO E → DOC 2, FREQ 1, POS 3; DOC 4, FREQ 1, POS 4

D1: MANEFO MANE MANE

D2: MANAGUERO, MANEHA, MANEBO, MANEHA

D3: MANAGUERA, MANEHAL, MANEFO, MANAGUERA

D4: MANAGUERA, MANAGUERA, MANEBO

D5: MANAGUERA, MANEFO

MANEBO ALGUN ERROR
 YA QUE NO APARECE LA POS
 2 DEL DOC 4.

TF-IDF → TF: TERMS DE QUEROY (CANT DE VECES QUE APARECE UN TÉRMINO DE Q CON DOC)

IDF → BUEN CRITÉRIO EN PESO INVERSAMENTE PROPORCIONAL A SU FREQ
 (los términos que aparecen en pocos docs son a ser más importantes que los q aparecen en pocos docs)

Q: "MANAGUERO MANEFO"

$IDF = \log \left(\frac{N+1}{F_{ti}} \right)$ → N: CANT. TOTAL DE DOC
 → CANT DE DOC QUE POSSE EL TÉRMINO

	TF					IDF
	D1	D2	D3	D4	D5	
MANAGUERA	0	0	2	2	1	$\log(6/3) = 0,301$
MANEFO	1	0	1	0	1	$\log(6/3) = 0,301$

PRIMA RANGUERO, CALIFICACION - $R(Q, D_j) = \sum F_{ti} \cdot IDF$ (Para cada término de Q y su cant. DOC)

D1 → $0 \cdot 0,301 + 1 \cdot 0,301 = 0,301$; D2 → 0; D3 → $2 \cdot 0,301 + 0,301 = 0,903$; D4 → $2 \cdot 0,301 = 0,602$

D5 → $1 \cdot 0,301 + 1 \cdot 0,301 = 0,602$

RANKING → 1°: D3, 2°: D4, 3°: D5, 4°: D1

① A MUEBRES = SC.TextFile('muebres.csv')
 PORCENTAJE_PABA = SC.TextFile('pabas.csv')

Filtra las muebres por raza negra

MUEBRES_NEGROS = MUEBRES.FILTER (WHERE X: X[3] == "BLACK")
 .MAP (WHERE X: (X[4], 1)) → (ESTADO, 1)

Sumo las muebres

MUEBRES_NEGROS = MUEBRES_NEGROS.REDUCE BYKEY (WHERE X,Y: X+Y)

Me quedo con el estado de mayor cantidad de muebres ya que ese es el mayor porcentaje de muebres

MUEBRES_NEGROS.REDUCE (WHERE X,Y: X IF X[1] > Y[1] ELSE Y)

B # (STATE, ^{SURF.BUCK} ~~RAZA~~ NEGRO + 1)

RDD1 = PORCENTAJE_PABA.MAP (WHERE X: (X[0], (X[3], 1)))
 RDD1 = RDD1.REDUCE BYKEY (WHERE X,Y: (X[0] + Y[0], X[1] + Y[1]))

Sumo los porcentajes de cada ciudad y el consumo

Calculo el promedio por estado

RDD1 = RDD1.MAP (WHERE X: (X[0], X[1][0] / X[1][1]))

→ PROMEDIO

Ahora voy a usar reduce para calcular el porcentaje de las muebres

MUEBRES_NEGROS = MUEBRES_NEGROS.MAP (WHERE X: (X[0], X[1] / MUEBRES_NEGROS.COUNT()))

Sumo RDD1 con MUEBRES_NEGROS

RDD2 = RDD1.SUM (MUEBRES_NEGROS) → # (ESTADO, (PORCENTAJE_MUEBRES, PROMEDIO))

ANOTA ORIGEN LA DIFERENCIA ENTRE POSICIONES Y PROCESO

RDDZ = RDDZ, MAP(WITH X: (X[0], ABS(X[1][0] - X[1][1]))
ESTIMO DIFERENCIA

AME JUEGO CON EL TOPLO

RDDZ. TAKE ORSIZES (10, WITH X: -X[1])

② A) IMPORTAR PÁRAMETROS AS PD

```
MENSAJES = PD.REND-CSU('MENSAJES-CSU')  
CLIENTES = PD.REND-CSU('MENSAJES-CLIENTES-CSU')
```

ME QUEDO CON CLIENTES QUE EL NUMERO DE CUENTA MAYOR AL DADO

```
CLIENTES-FILTER = CLIENTES[CLIENTES['ACCOUNT-NUMBER'] > 25679747]
```

ME QUEDO CON LAS MENSAJES PEDIDAS

```
MENSAJES-PEDIDAS = MENSAJES[(MENSAJES['MESSAGE'] == 'AWS.VPC.NETWORK-IN') |  
                              OR(MENSAJES['MESSAGE'] == 'AWS.VPC.NETWORK-PAUSE') |  
                              OR(MENSAJES['MESSAGE'] == 'AWS.VPC.NETWORK-OUT')]
```

HAGO MERGE 'INNER' POR CLIENTE-ID

```
MERGES = CLIENTES-FILTER.MERGE(MENSAJES-PEDIDAS, ON='CLIENT-ID')
```

AGRUPO POR MESSAGE Y ACCOUNT-NUMBER

```
MERGES = MERGES.GROUPBY(['MESSAGE', 'ACCOUNT-NUMBER']).agg({'VALUE': 'TEAM'})  
MERGES = MERGES.GROUPBY(['MESSAGE', 'ACCOUNT-NUMBER']).agg({'VALUE': 'TEAM'})
```

```
MERGES.CUSTACK().T.RENAME(COLUMNS = {'AWS.VPC.NETWORK-IN': 'AWS.VPC.NETWORK-IN-TEAM',  
                                          'AWS.VPC.NETWORK-OUT': 'AWS.VPC.NETWORK-OUT-TEAM',  
                                          'AWS.VPC.NETWORK-PAUSE': 'AWS.VPC.NETWORK-PAUSE-TEAM'})
```


③ B)

$$v_1 = [1, 5, 3, 2], v_2 = [0, 0, 1, 7], v_3 = [4, 4, 5, 0], v_4 = [5, 1, 0, 1]$$

¿CÓMO SEACH DE IMPEDIMOS con $b=1, r=4$. ¿CÓMO IMPEDIMOS CADA UNO PERO QUE
EL + SUMA DE A v_1 SEA v_3

CANTIDAD DE $MH \rightarrow r \times b = 4$

PARA QUE LOS 2 SEAS SUMADOS, DEBE QUE POR ENADA EL MAYOR VALOR DE
PROPORCION UNIDAD ENTRE LOS SEAS Y LOS IMPEDIMOS

$$u_1 = [1, -1, -1, 1] \rightarrow \begin{cases} v_1 \cdot u_1 = 0 \\ v_2 \cdot u_1 > 0 \\ v_3 \cdot u_1 < 0 \\ v_4 \cdot u_1 > 0 \end{cases} \rightarrow \begin{cases} MH_1 = 1 \\ MH_2 = -1 \\ MH_3 = 1 \\ MH_4 = -1 \end{cases} \left. \vphantom{\begin{matrix} v_1 \cdot u_1 = 0 \\ v_2 \cdot u_1 > 0 \\ v_3 \cdot u_1 < 0 \\ v_4 \cdot u_1 > 0 \end{matrix}} \right\} v_1 \text{ SUMA A } v_3$$

$$u_2 = [-1, 1, 1, 1] \rightarrow \begin{cases} v_1 \cdot u_2 > 0 \\ v_2 \cdot u_2 < 0 \\ v_3 \cdot u_2 > 0 \\ v_4 \cdot u_2 < 0 \end{cases} \left. \vphantom{\begin{matrix} v_1 \cdot u_2 > 0 \\ v_2 \cdot u_2 < 0 \\ v_3 \cdot u_2 > 0 \\ v_4 \cdot u_2 < 0 \end{matrix}} \right\} \begin{cases} MH_1 = 1 \\ MH_2 = -1 \\ MH_3 = 1 \\ MH_4 = -1 \end{cases} \left. \vphantom{\begin{matrix} v_1 \cdot u_2 > 0 \\ v_2 \cdot u_2 < 0 \\ v_3 \cdot u_2 > 0 \\ v_4 \cdot u_2 < 0 \end{matrix}} \right\} v_1 \text{ SUMA A } v_3$$

$$u_3 = [1, 1, 1, 1] \rightarrow v_1 \cdot u_3 > 0$$

$$u_4 = [1, 1, 1, -1] \rightarrow v_1 \cdot u_4 = 0$$

$$v_2 \cdot u_4 < 0$$

$$v_3 \cdot u_4 > 0$$

$$v_4 \cdot u_4 > 0$$

$$u_5 = [1, 1, 1, 1]$$

$$u_3 = [-1, -1, -1, -1] \rightarrow \begin{cases} v_1 \cdot u_3 < 0 \\ v_2 \cdot u_3 < 0 \\ v_3 \cdot u_3 < 0 \\ v_4 \cdot u_3 < 0 \end{cases}$$

$$u_4 = [1, 1, 1, 1]$$

→ COMO YA EXISTEN 2 IMPEDIMOS ADEMAS
QUE UNOS QUE v_1 Y v_3 SON SUMADOS,
NO CREAN EL PROBLEMA

	MH_1	MH_2	MH_3	MH_4
v_1	1			
v_2				
v_3				
v_4				

	u_1	u_2	u_3	u_4
u_1	1	-1	1	-1
u_2	1	-1	1	-1
u_3	-1	-1	-1	-1
u_4	1	-1	1	1

v_1 Y v_3 SUMADOS EN RESOL
LOS MH USADOS

$$u_1 = [1, -1, -1, 1]$$

$$u_2 = [-1, 1, 1, 1]$$

$$u_3 = [-1, -1, -1, -1]$$

$$u_4 = [1, 1, 1, -1]$$